LAPORAN

PENAMBANGAN DATA LANJUT

TUGAS 1

KLASIFIKASI PEMBELIAN PELANGGAN MENGGUNAKAN METODE ENSEMBLE (STACKING)

Disusun Oleh:

Nazly Rafa Oktafian Nuzqu : 2311103078

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS REKAYASA INDUSTRI

UNIVERSITAS TELKOM

2025

DAFTAR ISI

DAFTAR ISI ii
DAFTAR GAMBAR iv
DAFTAR TABEL v
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 1
1.3 Tujuan 1
1.4 Manfaat 2
BAB II TINJAUAN PUSTAKA 3
2.1 Data Mining 3
2.2 Preprocessing Data 3
2.3 Metode Ensemble 3
2.4 Random Forest 3
2.5 Gradient Boosting 4
2.6 Stacking Ensemble 4
2.7 Metrik Evaluasi 4
BAB III METODOLOGI 6
3.1 Dataset 6
3.2 Alur Metodologi 6
3.3 Tools dan Library 7
BAB IV HASIL DAN PEMBAHASAN 8
4.1 Data Understanding 8
4.2 Exploratory Data Analysis (EDA) 9
4.2.1 Distribusi Fitur Numerik 9
4.2.2 Distribusi Fitur Kategorik 10

4.2.3 Deteksi Outlier 10
4.2.4 Correlation Heatmap 11
4.3 Preprocessing Data 11
4.3.1 Menghapus Kolom Tidak Relevan 12
4.3.2 Standarisasi Data Kategorikal 12
4.3.3 Menghapus Data Duplikat 12
4.3.4 Penanganan Missing Values 13
4.3.5 Encoding Fitur Kategorikal 13
4.3.6 Pembagian Data Latih dan Tes 14
4.3.7 Feature Scaling 15
4.4 Pemodelan: Stacking Ensemble 15
4.4.1 Arsitektur Model 15
4.4.2 Proses Stacking 15
4.5 Evaluasi Model 16
4.5.1 Metrik Evaluasi 16
4.5.2 Classification Report 16
4.5.3 Analisis Hasil 17
BAB V PENUTUP 18
5.1 Kesimpulan 18
5.2 Saran 18
VIDEO PRESENTASI PROJECT 20

DAFTAR GAMBAR

Gambar 1. CRISP-DM Process 7
Gambar 2. Daftar Fitur dan Tipe Data 8
Gambar 3. Jumlah Data Duplikat 9
Gambar 4. Jumlah Missing Values 9
Gambar 5. Distribusi Fitur Numerik 9
Gambar 6. Distribusi Fitur Kategorik 10
Gambar 7. Deteksi Outlier Menggunakan Boxplot 10
Gambar 8. Correlation Heatmap 11
Gambar 9. Menghapus Fitur Tidak Relevan 12
Gambar 10. Feature Engineering 12
Gambar 11. Menghapus Data Duplikat 13
Gambar 12. Label Encoding 14
Gambar 13. One Hot Encoding 14
Gambar 14. Feature Scaling 15
Gambar 15. Stacking Classifier 16
Gambar 16. Classification Report 17

DAFTAR TABEL

Tabel 1. Daftar Fitur Dataset 6
Tabel 2. Daftar Library 7
Tabel 3. Detail Outlier 11
Tabel 4. Detail Penanganan Imputasi 13
Tabel 5. Pembagian Data Latih dan Tes 14
Tabel 6. Arsitektur Model 15
Tabel 7. Metrik Evaluasi 16

BAB I
PENDAHULUAN

1.1 Latar Belakang

Di era digital yang semakin berkembang, perusahaan menghadapi tantangan besar dalam memahami perilaku pelanggan secara akurat dan efisien. Salah satu permasalahan utama dalam dunia bisnis adalah memprediksi apakah seorang pelanggan akan melakukan pembelian atau tidak, sehingga perusahaan dapat mengambil keputusan yang lebih tepat sasaran dalam strategi pemasaran, pengelolaan inventaris, maupun program loyalitas pelanggan.

Data Mining hadir sebagai solusi untuk mengekstrak pengetahuan (knowledge) yang bermakna dari data bervolume besar. Salah satu teknik dalam data mining yang banyak digunakan adalah klasifikasi, yaitu proses memetakan data ke dalam kategori atau kelas tertentu berdasarkan pola yang dipelajari dari data historis.

Dalam project ini, digunakan dataset pelanggan (customer data) yang berisi 500.000+ data transaksi dan atribut pelanggan. Dataset ini mencerminkan kondisi nyata di mana data memiliki berbagai permasalahan seperti missing values, inkonsistensi format, dan data duplikat, sehingga proses preprocessing menjadi tahap yang sangat krusial sebelum pemodelan dilakukan.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam project ini adalah:

1. Dataset pelanggan mengandung berbagai permasalahan kualitas data seperti missing values, data duplikat, dan inkonsistensi format yang perlu ditangani sebelum pemodelan.
2. Diperlukan model klasifikasi yang mampu memprediksi status pembelian pelanggan (PurchaseStatus) secara akurat menggunakan metode ensemble.
3. Perlu dilakukan evaluasi untuk mengukur sejauh mana performa model ensemble yang dibangun dalam mengklasifikasikan data pelanggan.

1.3 Tujuan

Tujuan dari project data mining ini adalah:

1. Melakukan preprocessing data secara menyeluruh agar data siap digunakan dalam proses pemodelan.
2. Membangun model klasifikasi menggunakan metode Stacking Ensemble untuk memprediksi status pembelian pelanggan.
3. Mengevaluasi performa model menggunakan metrik Accuracy, ROC-AUC, Precision, Recall, dan F1-Score.

1.4 Manfaat

1. Bagi akademik: Memberikan pemahaman praktis tentang penerapan metode ensemble dalam kasus klasifikasi data pelanggan berskala besar.
2. Bagi bisnis: Model yang dihasilkan dapat digunakan sebagai dasar sistem identifikasi pelanggan yang berpotensi melakukan pembelian, sehingga tim pemasaran dapat menargetkan promosi secara lebih efisien.
3. Bagi pengembangan ilmu: Memberikan contoh nyata bagaimana tahapan preprocessing yang baik berkontribusi signifikan terhadap kualitas model prediktif.

BAB II
TINJAUAN PUSTAKA

2.1 Data Mining

Data mining adalah proses mengekstraksi pola, informasi, dan pengetahuan yang berguna dari sekumpulan data berukuran besar. Proses ini mencakup berbagai teknik dari statistik, machine learning, dan database untuk menemukan hubungan tersembunyi dalam data. Salah satu tugas utama dalam data mining adalah klasifikasi, yaitu proses pembelajaran model yang mampu memetakan data input ke dalam kelas atau kategori tertentu.

2.2 Preprocessing Data

Preprocessing data merupakan tahap awal yang sangat penting dalam data mining. Data dunia nyata seringkali tidak sempurna mengandung nilai yang hilang (*missing values*), data duplikat, inkonsistensi format, dan outlier. Tahapan preprocessing yang umum dilakukan meliputi:

- Data Cleaning: Menangani missing values, menghapus duplikat, dan memperbaiki inkonsistensi.
- Data Transformation: Encoding variabel kategorikal, normalisasi/standarisasi fitur numerik.
- Data Reduction: Mengurangi dimensi data tanpa kehilangan informasi penting.

2.3 Metode Ensemble

Metode ensemble adalah pendekatan dalam machine learning yang menggabungkan beberapa model (learner) untuk menghasilkan prediksi yang lebih baik dibandingkan model tunggal. Ide dasarnya adalah bahwa kombinasi beberapa model yang lemah (weak learners) dapat menghasilkan model yang lebih kuat (strong learner). Metode ensemble bekerja efektif karena setiap model memiliki kelebihan dan kekurangan masing-masing, sehingga kombinasinya dapat saling menutupi kelemahan. Terdapat tiga teknik ensemble yang paling populer, yaitu Bagging, Boosting, dan Stacking.

2.4 Random Forest

Random Forest adalah algoritma ensemble berbasis bagging yang membangun sejumlah pohon keputusan (decision tree) secara paralel menggunakan subset data (bootstrap sampling) dan subset fitur yang dipilih secara acak pada setiap node. Prediksi

akhir dihasilkan melalui voting mayoritas dari seluruh pohon untuk kasus klasifikasi. Keacakan dalam pemilihan data dan fitur inilah yang membuat Random Forest sangat kuat terhadap overfitting, mampu menangani data berdimensi tinggi, serta relatif tidak sensitif terhadap outlier dan missing values.

2.5 Gradient Boosting

Gradient Boosting adalah algoritma ensemble berbasis *boosting* yang membangun pohon keputusan secara sekuensial, di mana setiap pohon baru dibangun untuk memperbaiki kesalahan residual dari pohon sebelumnya. Proses optimasi dilakukan menggunakan gradient descent untuk meminimalkan fungsi loss. Dibandingkan Random Forest, Gradient Boosting umumnya menghasilkan akurasi yang lebih tinggi pada data yang kompleks, namun membutuhkan waktu pelatihan yang lebih lama dan lebih rentan terhadap overfitting jika parameter tidak diatur dengan baik.

2.6 Stacking Ensemble

Stacking (Stacked Generalization) adalah metode ensemble yang menggunakan prediksi dari beberapa model dasar (base learner) sebagai fitur input untuk melatih model meta (meta-learner). Berbeda dengan bagging dan boosting, stacking memungkinkan kombinasi model yang heterogen (berbeda jenis algoritmanya), sehingga dapat memanfaatkan keunggulan dari masing-masing algoritma secara bersamaan. Prosesnya adalah sebagai berikut:

- Base learner dilatih menggunakan cross-validation pada data training untuk menghasilkan prediksi out-of-fold.
- Prediksi (atau probabilitas) dari seluruh base learner digabung menjadi fitur baru (meta-features).
- Meta-learner dilatih menggunakan meta-features tersebut untuk menghasilkan prediksi akhir.

Penggunaan cross-validation dalam proses ini bertujuan untuk mencegah data leakage dan memastikan meta-learner dilatih pada prediksi yang benar-benar bersifat out-of-sample.

2.7 Metrik Evaluasi

Untuk mengukur performa model klasifikasi, digunakan beberapa metrik evaluasi berikut:

- Accuracy: Persentase prediksi yang benar dari total seluruh prediksi. Cocok digunakan ketika distribusi kelas relatif seimbang.
- Precision: Proporsi prediksi positif yang benar-benar positif. Penting ketika biaya false positive tinggi.
- Recall: Proporsi data positif yang berhasil dideteksi oleh model. Penting ketika biaya false negative tinggi.
- F1-Score: Rata-rata harmonik dari Precision dan Recall, berguna saat terdapat ketidakseimbangan kelas.
- ROC-AUC: Mengukur kemampuan model dalam membedakan kelas positif dan negatif di berbagai threshold. Nilai mendekati 1 menunjukkan performa diskriminasi yang sangat baik.

BAB III
METODOLOGI

3.1 Dataset

Dataset yang digunakan dalam project ini adalah data pelanggan yang bersumber dari file customerData_500k.csv. Dataset ini merupakan data transaksi dan atribut pelanggan yang mencerminkan kondisi nyata di mana terdapat berbagai permasalahan kualitas data. Dataset terdiri dari 502.500 baris dan 19 kolom dengan campuran tipe data numerik dan kategorikal. Variabel target yang digunakan adalah PurchaseStatus, yang merepresentasikan apakah seorang pelanggan melakukan pembelian (1) atau tidak (0).

Berikut adalah daftar fitur dalam dataset:

Tabel 1. Daftar Fitur Dataset

No	Nama Kolom	Tipe Data	Keterangan
1	CustomerID	Object	ID unik pelanggan
2	Age	Float	Usia pelanggan
3	AnnualIncome	Float	Pendapatan tahunan
4	NumberOfPurchases	Integer	Jumlah pembelian
5	TimeSpentOnWebsite	Float	Waktu di website (menit)
6	CustomerTenureYears	Float	Lama menjadi pelanggan
7	LastPurchaseDaysAgo	Float	Hari sejak pembelian terakhir
8	Gender	Object	Jenis kelamin
9	ProductCategory	Object	Kategori produk
10	PreferredDevice	Object	Perangkat yang digunakan
11	Region	Object	Wilayah pelanggan
12	ReferralSource	Object	Sumber referral
13	CustomerSegment	Object	Segmen pelanggan
14	LoyaltyProgram	Integer	Status program loyalitas
15	DiscountsAvailed	Integer	Diskon yang digunakan
16	SessionCount	Integer	Jumlah sesi
17	CustomerSatisfaction	Float	Skor kepuasan pelanggan
18	PurchaseStatus	Integer	Status pembelian (target)
19	PromoCode	Object	Kode promo

3.2 Alur Metodologi

Dalam project ini, alur pengerjaan dilakukan secara sistematis dan bertahap untuk memastikan setiap proses berjalan dengan baik dan menghasilkan model yang optimal. Secara garis besar, alur metodologi yang diterapkan adalah sebagai berikut:

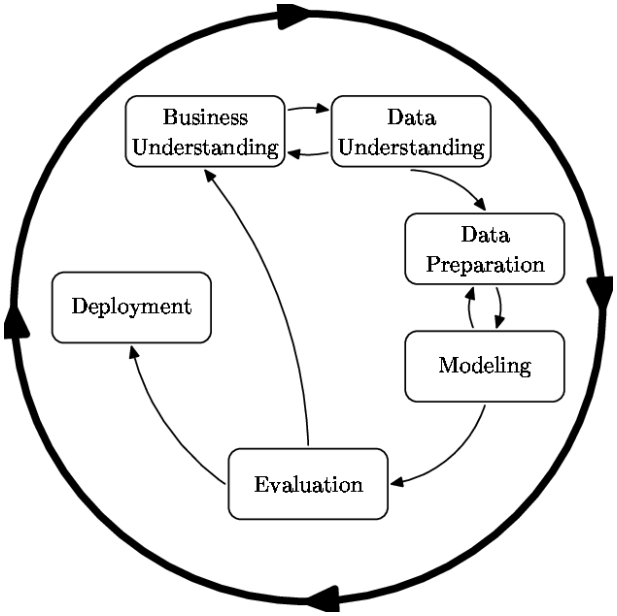

Gambar 1. CRISP-DM Process

Setiap tahapan memiliki peran yang saling berkaitan. Dimulai dari pengumpulan data, kemudian memahami karakteristik data, melakukan eksplorasi secara visual, membersihkan dan mempersiapkan data, hingga akhirnya membangun dan mengevaluasi model. Tahapan preprocessing menjadi tahap yang paling krusial karena kualitas data yang masuk ke model sangat menentukan performa hasil akhir.

3.3 Tools dan Library

Project ini dikerjakan menggunakan bahasa pemrograman Python yang dijalankan pada lingkungan Jupyter Notebook. Python dipilih karena memiliki ekosistem library yang sangat lengkap dan mendukung seluruh tahapan dalam proses data mining, mulai dari manipulasi data hingga pemodelan machine learning. Berikut adalah library utama yang digunakan beserta fungsinya:

Tabel 2. Daftar Library

Library	Kegunaan
Pandas	Manipulasi dan analisis data tabular
Numpy	Komputasi numerik dan operasi array
Matplotlib	Visualisasi data dalam bentuk grafik dan plot
Seaborn	Visualisasi data statistik yang lebih informatif
Scikit-learn	Preprocessing, pemodelan ensemble, dan evaluasi model

BAB IV
HASIL DAN PEMBAHASAN

4.1 Data Understanding

Tahap data understanding merupakan langkah awal yang dilakukan untuk memahami struktur, karakteristik, dan kualitas dataset sebelum masuk ke tahap preprocessing. Pada tahap ini dilakukan eksplorasi menyeluruh terhadap dataset untuk mengidentifikasi potensi permasalahan yang perlu ditangani. Berikut adalah hasil dari proses data understanding yang telah dilakukan.

Dataset memiliki 502.500 baris dan 19 kolom dengan campuran tipe data numerik dan kategorikal. Berdasarkan hasil eksplorasi, ditemukan beberapa permasalahan kualitas data sebagai berikut:

- Terdapat 4 kolom dengan missing values berkisar 3% per kolom, yaitu Age, AnnualIncome, Gender, dan Region
- Ditemukan 2.500 baris duplikat dalam dataset
- Kolom Gender memiliki 6 variasi format yang tidak konsisten seperti Male, male, M, Female, female, dan F
- Kolom Region memiliki 96 variasi format akibat perbedaan kapitalisasi
- Terdapat outlier pada beberapa fitur numerik, terutama CustomerTenureYears sebesar 4.96%

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 502500 entries, 0 to 502499
Data columns (total 19 columns):
 #   Column                Non-Null Count   Dtype
---  ------                --------------   -----
 0   CustomerID            502500 non-null  object
 1   Age                   487417 non-null  float64
 2   AnnualIncome          487486 non-null  float64
 3   NumberOfPurchases     502500 non-null  int64
 4   TimeSpentOnWebsite    502500 non-null  float64
 5   CustomerTenureYears   502500 non-null  float64
 6   LastPurchaseDaysAgo   502500 non-null  int64
 7   Gender                487419 non-null  object
 8   ProductCategory       502500 non-null  object
 9   PreferredDevice       502500 non-null  object
 10  Region                487425 non-null  object
 11  ReferralSource        502500 non-null  object
 12  CustomerSegment       502500 non-null  object
 13  LoyaltyProgram        502500 non-null  int64
 14  DiscountsAvailed      502500 non-null  int64
 15  SessionCount          502500 non-null  int64
 16  CustomerSatisfaction  502500 non-null  int64
 17  PurchaseStatus        502500 non-null  int64
 18  PromoCode             502500 non-null  object
dtypes: float64(4), int64(7), object(8)
memory usage: 72.8+ MB
```

Gambar 2. Daftar Fitur dan Tipe Data

```
df.duplicated().sum()
```

```
np.int64(2500)
```

Gambar 3. Jumlah Data Duplikat

	Missing Count	Missing (%)
Age	15083	3.001592
Gender	15081	3.001194
Region	15075	3.000000
AnnualIncome	15014	2.987861

Gambar 4. Jumlah Missing Values

4.2 Exploratory Data Analysis (EDA)

Setelah memahami kondisi awal dataset, dilakukan Exploratory Data Analysis (EDA) untuk menggali informasi lebih dalam mengenai pola dan distribusi data secara visual. EDA bertujuan untuk memberikan gambaran yang lebih komprehensif mengenai karakteristik setiap fitur sebelum dilakukan pemodelan. Berikut adalah hasil visualisasi EDA yang telah dilakukan.

4.2.1 Distribusi Fitur Numerik

Visualisasi histogram dilakukan pada seluruh fitur numerik untuk melihat sebaran data masing-masing fitur. Hasil visualisasi menunjukkan bahwa mayoritas fitur numerik memiliki distribusi yang cukup normal. Fitur TimeSpentOnWebsite dan CustomerTenureYears memiliki distribusi yang lebih lebar dengan beberapa nilai ekstrem di bagian ekor distribusi.

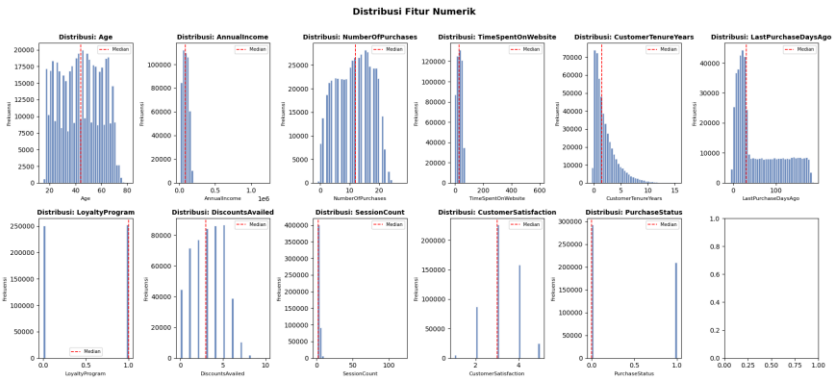

Gambar 5. Distribusi Fitur Numerik

4.2.2 Distribusi Fitur Kategorik

Visualisasi bar chart horizontal dilakukan pada seluruh fitur kategorikal untuk melihat frekuensi kemunculan setiap kategori. Hasil menunjukkan bahwa distribusi Gender cukup seimbang antara Male dan Female, sedangkan distribusi Region relatif merata pada keempat wilayah yaitu South, North, East, dan West. Seperti yang sebelumnya dijelaskan di atas, untuk fitur gender dan region perlu dilakukannya feature engineering untuk menyelaraskan nilai yang ada di dalamnya.

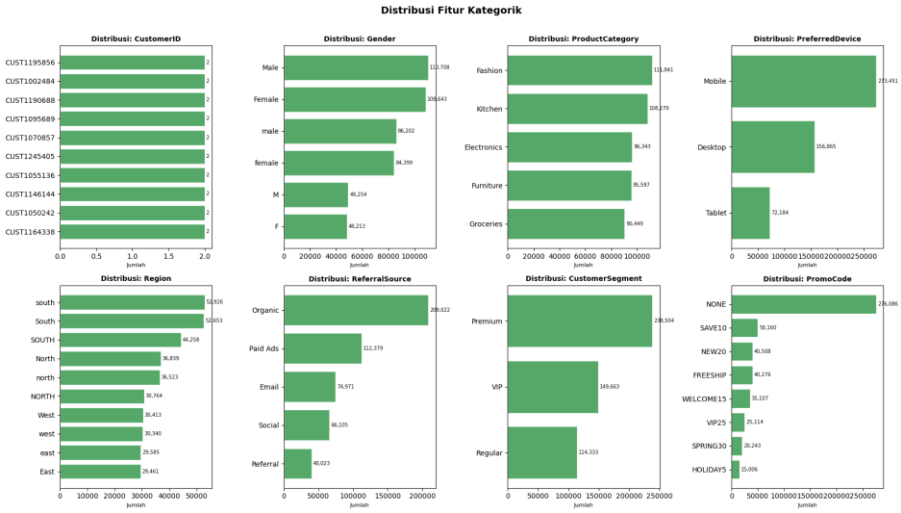

Gambar 6. Distribusi Fitur Kategorik

4.2.3 Deteksi Outlier

Deteksi outlier dilakukan menggunakan Boxplot dan metode IQR (Interquartile Range) pada seluruh fitur numerik. Hasil deteksi menunjukkan adanya outlier pada beberapa fitur seperti yang ditampilkan pada gambar berikut:

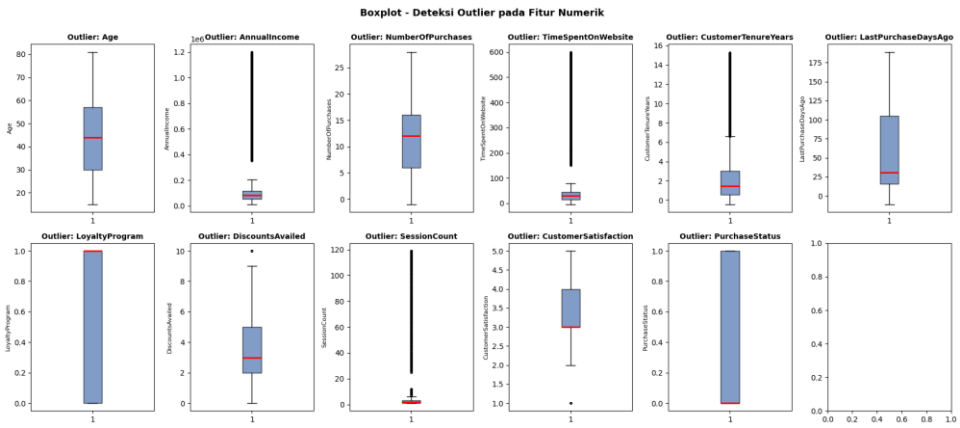

Gambar 7. Deteksi Outlier Menggunakan Boxplot

Berikut merupakan penjabaran lebih detail dari nilai outlier / persentase dari tiap-tiap fitur numerik di atas:

Tabel 3. Detail Outlier

Fitur	Jumlah Outlier	Persentase
AnnualIncome	2.518	0.50%
TimeSpentOnWebsite	2.520	0.50%
CustomerTenureYears	24.927	4.96%
SessionCount	9.963	1.98%
DiscountsAvailed	59	0.01%

4.2.4 Correlation Heatmap

Analisis korelasi dilakukan untuk mengidentifikasi hubungan linear antar fitur numerik menggunakan heatmap. Hasil menunjukkan bahwa tidak terdapat korelasi yang sangat tinggi antar fitur, yang mengindikasikan multikolinearitas rendah. Dengan demikian, seluruh fitur dipertahankan dan tidak ada fitur yang perlu dihapus berdasarkan analisis korelasi.

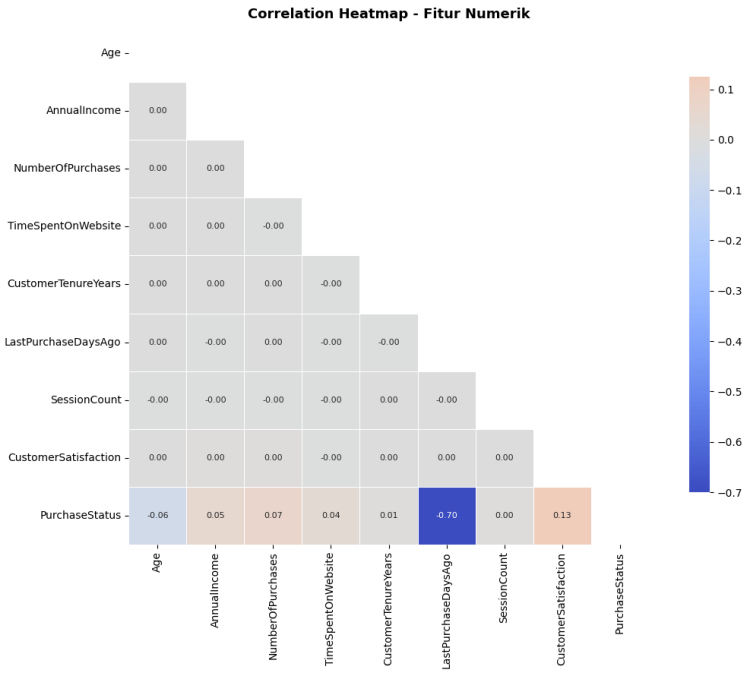

Gambar 8. *Correlation Heatmap*

4.3 Preprocessing Data

Setelah tahap EDA, dilakukan preprocessing untuk membersihkan dan mempersiapkan data agar siap digunakan dalam proses pemodelan. Preprocessing dilakukan secara bertahap dan sistematis mengikuti permasalahan yang telah diidentifikasi pada tahap sebelumnya. Berikut adalah detail setiap langkah preprocessing yang dilakukan.

4.3.1 Menghapus Kolom Tidak Relevan

Kolom CustomerID dihapus dari dataset karena bersifat sebagai identifier unik yang tidak memiliki nilai prediktif terhadap variabel target. Keberadaan kolom ini justru dapat mengganggu proses pemodelan apabila diikutsertakan.

```
df_clean.drop(columns=['CustomerID'], inplace=True)
```

Gambar 9. Menghapus Fitur Tidak Relevan

4.3.2 Standarisasi Data Kategorikal

Inkonsistensi format pada kolom Gender dan Region diselesaikan melalui proses standarisasi. Pada kolom Gender, semua variasi seperti male, M, dan MALE distandarisasi menjadi dua kategori bersih yaitu Male dan Female. Pada kolom Region, digunakan fungsi .str.strip().str.title() untuk menyeragamkan kapitalisasi sehingga menghasilkan 4 kategori bersih: South, North, East, dan West.

```
def standardize_gender(val):
    if pd.isna(val):
        return np.nan
    val = str(val).strip().lower()
    if val in ['male', 'M']:
        return 'Male'
    elif val in ['female', 'F']:
        return 'Female'
    else:
        return np.nan

df_clean['Gender'] = df_clean['Gender'].apply(standardize_gender)
df_clean['Gender'].unique()
```

```
array([nan, 'Female', 'Male'], dtype=object)
```

```
df_clean['Region'] = df_clean['Region'].str.strip().str.title()
df_clean['Region'].unique()
```

```
array(['South', 'East', 'West', 'North', nan], dtype=object)
```

Gambar 10. Feature Engineering

4.3.3 Menghapus Data Duplikat

Sebanyak 2.500 baris duplikat berhasil diidentifikasi dan dihapus menggunakan fungsi drop_duplicates(). Setelah proses ini, jumlah data berkurang dari 502.500 menjadi 500.000 baris dan tidak ditemukan lagi data duplikat.

```
df_clean = df_clean.drop_duplicates()
```

```
df_clean.duplicated().sum()
```

```
np.int64(0)
```

Gambar 11. Menghapus Data Duplikat

4.3.4 Penanganan Missing Values

Imputasi missing values dilakukan dengan pendekatan yang berbeda untuk fitur numerik dan kategorikal. Fitur numerik diisi menggunakan median karena lebih robust terhadap outlier dibandingkan mean, sedangkan fitur kategorikal diisi menggunakan modus karena merepresentasikan nilai yang paling sering muncul. Berikut adalah ringkasan hasil imputasi:

Tabel 4. Detail Penanganan Imputasi

Kolom	Metode	Nilai Pengisi
Age	Median	44.00
AnnualIncome	Median	84.069,38
Gender	Modus	Male
Region	Modus	South

Setelah proses imputasi, total missing values pada dataset menjadi 0.

4.3.5 Encoding Fitur Kategorikal

Proses encoding dilakukan untuk mengubah fitur kategorikal menjadi representasi numerik yang dapat diproses oleh algoritma machine learning. Terdapat dua metode encoding yang diterapkan sesuai dengan karakteristik masing-masing fitur. Label Encoding diterapkan pada kolom CustomerSegment karena fitur ini memiliki hierarki yang bermakna, dengan urutan Regular (0) - Premium (1) - VIP (2).

One-Hot Encoding diterapkan pada fitur nominal yaitu Gender, ProductCategory, PreferredDevice, Region, ReferralSource, dan PromoCode.

Parameter drop_first=True digunakan untuk menghindari multikolinearitas (dummy variable trap). Setelah proses OHE, jumlah fitur bertambah dari 18 menjadi 33 fitur.

```
# Label Encoding
segment_order = ['Regular', 'Premium', 'VIP']
segment_map   = {val: i for i, val in enumerate(segment_order)}
df_clean['CustomerSegment'] = df_clean['CustomerSegment'].astype(str).str.strip().str.title()
df_clean['CustomerSegment'] = df_clean['CustomerSegment'].map(segment_map)

n_nan = df_clean['CustomerSegment'].isna().sum()
if n_nan > 0:
    mode_series = df_clean['CustomerSegment'].dropna()
    fallback = int(mode_series.mode()[0]) if len(mode_series) > 0 else 0
    df_clean['CustomerSegment'] = df_clean['CustomerSegment'].fillna(fallback).astype(int)
else:
    df_clean['CustomerSegment'] = df_clean['CustomerSegment'].astype(int)
```

Gambar 12. Label Encoding

```
# One Hot Encoding
nominal_features = [
    'Gender', 'ProductCategory', 'PreferredDevice',
    'Region', 'ReferralSource', 'PromoCode'
]

df_before_ohe = df_clean.shape[1]
df_clean = pd.get_dummies(df_clean, columns=nominal_features,
                          drop_first=True,
                          dtype=int)
df_after_ohe = df_clean.shape[1]

df_clean.shape

(500000, 33)
```

Gambar 13. One Hot Encoding

4.3.6 Pembagian Data Latih dan Tes

Dataset dibagi menjadi training set dan testing set dengan rasio 80:20 menggunakan fungsi train_test_split. Parameter stratify=y digunakan untuk memastikan proporsi kelas target yang sama pada kedua set, sehingga model tidak mengalami bias akibat ketidakseimbangan distribusi kelas.

Tabel 5. Pembagian Data Latih dan Tes

Set	Jumlah Data
Training	400.000
Tes	100.000

4.3.7 Feature Scaling

Normalisasi fitur dilakukan menggunakan StandardScaler yang menghasilkan distribusi dengan mean = 0 dan standar deviasi = 1. Proses fitting StandardScaler hanya dilakukan pada data training untuk menghindari data leakage, kemudian hasil transformasinya diterapkan pada data testing.

```
# Feature Scaling
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled  = scaler.transform(X_test)
```

Gambar 14. Feature Scaling

4.4 Pemodelan: Stacking Ensemble

Setelah data selesai dipersiapkan, dilakukan proses pemodelan menggunakan metode Stacking Ensemble. Metode ini dipilih karena mampu memanfaatkan kekuatan dari beberapa algoritma sekaligus untuk menghasilkan prediksi yang lebih akurat dan robust dibandingkan model tunggal. Berikut adalah detail arsitektur dan proses pemodelan yang dilakukan.

4.4.1 Arsitektur Model

Model stacking yang dibangun terdiri dari dua base learner dan satu meta-learner dengan konfigurasi sebagai berikut:

Tabel 6. Arsitektur Model

Level	Model	Parameter Utama
Base Model 1	Random Forest	n_estimators=100, max_depth=10, min_samples_split=5
Base Model 2	Gradient Boosting	n_estimators=100, learning_rate=0.1, max_depth=5
Meta Model	Logistic Regression	max_iter=1000

4.4.2 Proses Stacking

Proses stacking dilakukan dengan skema 5-fold cross-validation menggunakan parameter stack_method='predict_proba', artinya meta-learner menerima input

berupa probabilitas prediksi dari masing-masing base learner, bukan label kelas langsung. Alur prosesnya adalah sebagai berikut:

1. Dataset training dibagi menjadi 5 fold untuk proses cross-validation
2. Random Forest dan Gradient Boosting dilatih pada 4 fold, kemudian menghasilkan prediksi probabilitas pada fold ke-5
3. Prediksi probabilitas dari kedua base learner digabung menjadi fitur baru (meta-features)
4. Logistic Regression sebagai meta-learner dilatih menggunakan meta-features tersebut
5. Pada data testing, prediksi dari base learner diinput ke meta-learner untuk menghasilkan prediksi akhir

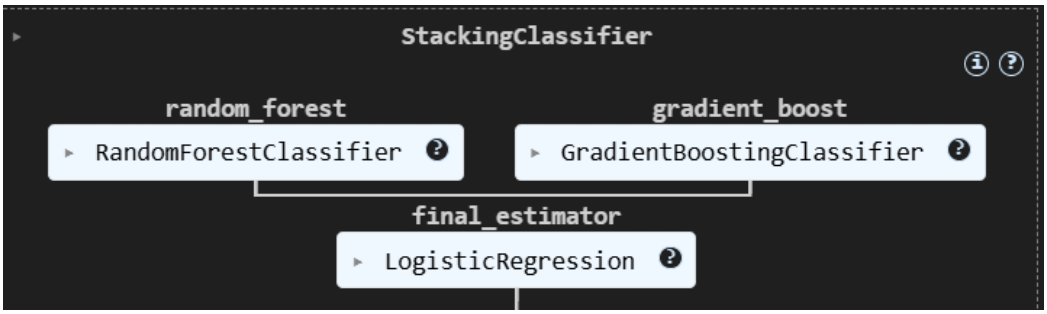

Gambar 15. Stacking Classifier

4.5 Evaluasi Model

Setelah model berhasil dilatih, dilakukan evaluasi untuk mengukur performa model pada data testing yang belum pernah dilihat sebelumnya. Evaluasi dilakukan menggunakan beberapa metrik yang relevan untuk kasus klasifikasi biner. Berikut adalah hasil evaluasi model Stacking Ensemble yang telah dibangun.

4.5.1 Metrik Evaluasi

Berikut metrik evaluasi yang digunakan:

Tabel 7. Metrik Evaluasi

Metrik	Nilai
Accuracy	92.18%
ROC-AUC	97.86%

4.5.2 Classification Report

Berikut merupakan classification report dari hasil evaluasi stacking modelnya:

```
Classification Report:
              precision    recall  f1-score   support

  Tidak Beli       0.95      0.92      0.93     58165
        Beli       0.89      0.93      0.91     41835

    accuracy                           0.92    100000
   macro avg       0.92      0.92      0.92    100000
weighted avg       0.92      0.92      0.92    100000
```

Gambar 16. Classification Report

4.5.3 Analisis Hasil

Berdasarkan hasil evaluasi yang diperoleh, model Stacking Ensemble menunjukkan performa yang sangat baik. Berikut adalah analisis dari masing-masing metrik evaluasi:

- Model berhasil mencapai akurasi 92.18% pada 100.000 data uji, yang berarti lebih dari 9 dari 10 prediksi yang dihasilkan model adalah benar.
- Nilai ROC-AUC sebesar 97.86% mengindikasikan kemampuan diskriminasi model yang sangat tinggi dalam membedakan pelanggan yang akan membeli dan yang tidak di berbagai threshold klasifikasi.
- Recall kelas "Beli" sebesar 0.93 menunjukkan bahwa model mampu mengidentifikasi 93% pelanggan yang benar-benar melakukan pembelian, yang sangat penting dari perspektif bisnis untuk memaksimalkan konversi.
- Performa model cukup seimbang antara kedua kelas dengan selisih F1-Score yang kecil (0.93 vs 0.91), menunjukkan tidak adanya bias signifikan meskipun distribusi kelas tidak sempurna seimbang.
- Penggabungan Random Forest yang unggul dalam menangani fitur berdimensi tinggi dengan Gradient Boosting yang kuat dalam menangkap pola non-linear melalui Stacking terbukti menghasilkan model yang lebih robust dan akurat.

BAB V
PENUTUP

5.1 Kesimpulan

Berdasarkan hasil project data mining yang telah dilakukan, dapat disimpulkan bahwa seluruh tahapan mulai dari preprocessing hingga pemodelan berhasil diselesaikan dengan baik. Pada tahap preprocessing, berbagai permasalahan kualitas data berhasil ditangani secara sistematis, meliputi penghapusan 2.500 data duplikat, standarisasi inkonsistensi format pada kolom Gender dan Region, imputasi missing values menggunakan median untuk fitur numerik dan modus untuk fitur kategorikal, serta encoding fitur kategorikal menggunakan Ordinal Encoding dan One-Hot Encoding. Setelah seluruh proses preprocessing selesai, dataset yang semula memiliki 502.500 baris dan 19 kolom berhasil dibersihkan menjadi 500.000 baris dengan 33 fitur yang siap digunakan untuk pemodelan.

Pada tahap pemodelan, metode Stacking Ensemble berhasil dibangun dengan menggabungkan Random Forest dan Gradient Boosting sebagai base learner, serta Logistic Regression sebagai meta-learner menggunakan skema 5-fold cross-validation. Pemilihan metode stacking didasari oleh kemampuannya dalam mengombinasikan kekuatan dua algoritma yang saling melengkapi, yaitu Random Forest yang unggul dalam menangani data berdimensi tinggi dan Gradient Boosting yang kuat dalam menangkap pola non-linear pada data.

Hasil evaluasi menunjukkan bahwa model Stacking Ensemble yang dibangun mampu menghasilkan performa yang sangat baik dengan nilai akurasi sebesar 92.18% dan ROC-AUC sebesar 97.86% pada 100.000 data uji. Performa model juga terbilang seimbang antara kedua kelas dengan F1-Score 0.93 untuk kelas "Tidak Beli" dan 0.91 untuk kelas "Beli", yang membuktikan bahwa model tidak mengalami bias signifikan terhadap salah satu kelas. Secara keseluruhan, penerapan metode Stacking Ensemble terbukti efektif dan dapat diandalkan untuk kasus klasifikasi prediksi pembelian pelanggan pada dataset berskala besar.

5.2 Saran

1. Dapat dilakukan hyperparameter tuning menggunakan GridSearchCV atau RandomizedSearchCV untuk lebih mengoptimalkan performa model.
2. Perlu dilakukan analisis feature importance untuk mengetahui fitur mana yang paling berpengaruh terhadap keputusan pembelian pelanggan.

3. Model dapat dibandingkan dengan metode ensemble lain seperti XGBoost atau LightGBM untuk mendapatkan baseline perbandingan yang lebih komprehensif.

VIDEO PRESENTASI PROJECT

Link video demo preprocessing dan hasil pemodelan ensemble:

https://drive.google.com/file/d/1tSojHPIgi-w_BlHuL_JXPqqMnSoHcIf3/view?usp=sharing